

Detectando desinformação sobre COVID-19 no WhatsApp: abordagens com embeddings contextuais para compreensão e geração em português brasileiro

Giulia Chimini Stefainski¹, Leonardo Azzi Martins¹, Matheus de Moraes Costa¹

¹Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)
Caixa Postal 15.064 – 91.501-970 – Porto Alegre – RS – Brazil

{giulia.stefainski, lamartins, matheus.costa}@inf.ufrgs.br

Abstract. *The spread of misinformation about COVID-19 on platforms like WhatsApp represent a significant challenge. This work investigates and compares the effectiveness of two language model approaches for misinformation detection in Brazilian Portuguese: one based on Natural Language Understanding (NLU) and another on Natural Language Generation (NLG). In order to do so, fine-tuning experiments were conducted with BERTimbau (NLU) and Qwen3-0.6B (NLG) models, and their performance were compared with that of traditional machine learning models. While BERTimbau outperformed previous approaches with an F1 score of 0.857, Qwen showed weaker performance at 0.787, only slightly above the original SVM baseline of 0.778.*

Resumo. *A disseminação de desinformação sobre a COVID-19 em plataformas como o WhatsApp representa um desafio significativo. Este trabalho investiga e compara a eficácia de duas abordagens de modelos de linguagem para a tarefa de detecção de desinformação em português brasileiro: uma baseada em compreensão de linguagem natural (NLU) e outra em geração (NLG). Para isso, foram realizados experimentos de fine-tuning com os modelos BERTimbau (NLU) e Qwen3-0.6B (NLG), além de comparar com modelos tradicionais de aprendizado de máquina. Enquanto o BERTimbau superou abordagens anteriores com uma pontuação F1 de 0.857, o Qwen apresentou desempenho inferior, com 0.787, apenas ligeiramente acima do baseline original do SVM, de 0.778.*

1. Introdução

Em 11 de Março de 2020, a Organização Mundial da Saúde (OMS) declarou a emergência de saúde pública do vírus COVID-19, que já se espalhava em diversos países, como uma situação pandêmica. Esta foi a primeira pandemia causada pelo coronavírus na história, segundo a OMS [Organização Mundial da Saúde 2020]. Neste período houve um grande crescimento da disseminação em massa de notícias falsas, boatos e rumores sobre a pandemia de COVID-19, principalmente através das redes sociais, contribuindo para um descrédito da ciência e das instituições globais de saúde [Galhardi et al. 2020]. No Brasil, o *WhatsApp* é a plataforma de mensagens mais popular do país [Vijaykumar et al. 2021] e foi um dos meios digitais mais utilizadas na disseminação de desinformação sobre COVID-19 [Galhardi et al. 2020], enquanto o país observou uma queda no interesse ou a rejeição da vacinação entre os brasileiros [Massuchin et al. 2021] e teve um dos maiores números de casos e mortes pela doença no mundo [Soares et al. 2021].

Neste contexto, a OMS cunhou o termo “infodemia” como um fenômeno de abundância de informação, acurada ou não, que se espalha entre humanos em períodos de emergência de saúde de uma maneira similar à uma epidemia, via sistemas físicos e digitais como plataformas de mídias sociais [Organização Mundial da Saúde 2021]. Para a organização, as pessoas precisam de informações acuradas para que possam adaptar o seu comportamento e proteger suas famílias e comunidades contra ameaças à saúde, especialmente durante períodos de pandemias e epidemias. Assim, dados textuais gerados por usuários nas plataformas digitais apresentam volumes massivos, dificuldade de acesso, semântica complexa e baixa qualidade, representando um desafio para seu processamento, estudo e compreensão [Alghamdi et al. 2023]. As formas de representação computacional da palavras como *embeddings* fixas, associadas a técnicas de aprendizado de máquina preditivas clássicas, apresentam limitações quanto à sua adaptação ao contexto semântico de onde ocorrem, e consequentemente limitam a tarefa de detecção de desinformação em textos de baixa qualidade — como em mensagens geradas por usuários no contexto da pandemia de COVID-19.

Neste mesmo período, ganhava força na área de Processamento de Linguagem Natural (PLN) abordagens de aprendizado profundas baseadas no mecanismo de atenção, como a arquitetura *Transformer* [Vaswani et al. 2017]. Esta arquitetura permitiu a representação de palavras como *embeddings* contextuais, capturando e codificando a semântica de cada ocorrência de uma palavra em um *corpus*, dados diferentes contextos [Alghamdi et al. 2023]. Assim, tornou-se possível empregar grandes modelos de linguagem (LLMs) pré-treinados em grandes volumes de *corpora* não rotulada para diversas tarefas de PLN, como tarefas de classificação de texto, contribuindo para a tarefa de detecção de desinformação [Alghamdi et al. 2023].

Este artigo explora a hipótese de que a utilização de modelos de linguagem baseados em *embeddings* contextuais podem promover ganhos de desempenho na tarefa de detecção de desinformação em mensagens de usuários do *WhatsApp*, especialmente no contexto de mensagens em português brasileiro. Para isto, o objetivo foi comparar os resultados obtidos com os resultados de [Martins et al. 2021b], que utilizou o *dataset* COVID.BR [Martins et al. 2021a] para realizar experimentos com *embeddings* fixas e algoritmos de classificação preditivos. Assim, foram propostos dois experimentos com modelos de linguagem com *embeddings* contextuais: com arquitetura *encoder-only*, para uma abordagem de compreensão de linguagem natural (NLU); e com arquitetura *decoder-only*, para uma abordagem de geração de linguagem natural (NLG). Foram selecionados dois modelos pré-treinados para cada uma destas abordagens, o BERTimbau e o *Qwen3-0.6B*, respectivamente. Realizou-se *fine-tuning* em ambos os modelos utilizando o *dataset* COVID.BR, através da adição de uma camada linear para classificação. Para comparar os resultados com [Martins et al. 2021b] foi realizada uma avaliação de desempenho com validação cruzada, com $k = 5$, e os resultados foram quantificados com as métricas *F1-score*, precisão, revocação e taxa de falso-positivos. Os resultados obtidos reportam um ganho de desempenho de ambas as abordagens em relação aos resultados de [Martins et al. 2021a], onde o modelo BERTimbau apresenta o maior ganho com um *F1-score* médio de 0.857 ± 0.018 , enquanto o melhor modelo em [Martins et al. 2021a] apresenta uma média de 0.778, demonstrando o potencial das *embeddings* contextuais para detecção de desinformação em *corpora* de baixa qualidade — como mensagens de texto no *WhatsApp*.

A seção 2 aborda os trabalhos utilizados como referência e comparação para os experimentos propostos. A seção 3 apresenta e descreve o conjunto de dados COVID.BR, utilizado neste estudo. A seção 4 apresenta a metodologia proposta e seus procedimentos para o desenvolvimento e reprodução dos experimentos. A seção 5 descreve a Análise Exploratória de Dados realizada no *dataset* COVID.BR, com objetivo de descrever e compreender os dados disponíveis para a tarefa de aprendizado de máquina. A seção 6 apresenta as ferramentas e parametrizações utilizadas em cada experimento, assim como as métricas quantitativas, os achados obtidos e a discussão dos resultados. Por fim, a seção 7 sumariza o trabalho realizado e realiza considerações.

2. Trabalhos relacionados

Em [Martins et al. 2021b], os autores utilizam o *dataset* COVID.BR para investigar métodos de aprendizado de máquina tradicionais para detecção automática de desinformação. Os algoritmos de classificação utilizados nos experimentos foram: Regressão Logística, *Bernoulli Naive-Bayes* (com *Bag of Words*, *Complement Naive-Bayes* (com *TF-IDF*), *Support Vector Machines* com *Kernel Linear* (LSVM), *K-Nearest Neighbors* (KNN), *Random Forest*, *Gradient Boosting* e *Multilayer Perceptron Neural Network* (MLP).

Diferentes técnicas foram combinadas ao algoritmo no experimento, compondo 12 diferentes cenários: técnicas de vetorização, como *Bag of Words* ou *TF-IDF*; diferentes n-gramas; e passos adicionais de pré-processamento, como lematização e remoção de *stop-words*. A avaliação destes experimentos foi realizada com validação cruzada, com $k = 5$, onde as métricas utilizadas foram: taxa de falso-positivos (FPR), precisão (PRE), revocação (REC) e *F1-score* (F1). O melhor experimento atingiu um *F1-score* de 0.778 com uma *Support Vector Machine* (SVM) treinada com descida de gradiente estocástica. A Tabela 1 apresenta os dez melhores experimentos, ordenados de acordo com seu *F1-score*.

Tabela 1. Resultados de [Martins et al. 2021b] ordenados por F1-Score

Algoritmo	Vetorização	n-gramas	Pré-processamento	FPR	PRE	REC	F1
SVM-SGD	BOW	3	Lematização	0.146	0.771	0.791	0.778
Naive-Bayes	BOW	2	Lematização	0.179	0.734	0.840	0.774
	BOW	1	-	0.183	0.734	0.833	0.771
	BOW	1	Lematização	0.182	0.728	0.836	0.770
	BOW	1	Lematização	0.183	0.730	0.836	0.769
	BOW	2	-	0.181	0.733	0.827	0.768
	BOW	3	-	0.178	0.736	0.821	0.768
	TF-IDF	2	Lematização	0.159	0.755	0.789	0.766
LSVM	TF-IDF	2	Lematização	0.158	0.765	0.773	0.763
MLP	TF-IDF	2	-	0.157	0.778	0.756	0.760

3. Dataset

O COVID19.BR é um *dataset* composto por mensagens de texto em português brasileiro relacionadas ao COVID-19, extraídas de grupos do aplicativo *WhatsApp*, anonimizadas e anotadas em larga escala com um rótulo para classificação de desinformação.

Para a criação do conjunto de dados, foram coletadas 228.061 mensagens, publicadas entre abril e junho de 2020, de 236 grupos públicos do *WhatsApp* com pelo

menos 100 membros. Esta versão ainda não rotulada contém dados e metadados sobre a mensagem, como dados temporais, dados de localidade, contagem do número de mídias, *URLs*, palavras, caracteres e compartilhamentos, e por fim o corpo da mensagem. Deste conjunto, foram filtradas para o processo de anotação 2.899 instâncias por ocorrências de palavras-chave como “*covid*”, “*coron*”, “*virus*”, “*china*”, “*chines*”, “*cloroquin*” e “*vacina*”. A anotação foi realizada manualmente, onde três pessoas especialistas rotularam as mensagens como desinformação ou não-desinformação. Dentre as pessoas anotadoras especialistas, duas são cientistas da computação e uma é socióloga, e as discordâncias sobre rótulos foram resolvidas com revisões coletivas [Martins et al. 2021a].

Os autores em [Martins et al. 2021a] utilizam como base da rotulação manual a definição de [Su et al. 2020], onde desinformação se refere a uma informação mal-representada em um macro-aspecto, incluindo diversos tipos de informações fabricadas, enganosas, falsas, ilusórias ou distorcidas. Segundo os autores, são geralmente criadas com intenções maliciosas pelos criadores da informação, minando a credibilidade da informação. O método de anotação utilizou plataformas de checagem de fatos quando as informações são verificáveis, disponibilizando a fonte utilizada no dataset. Para mensagens que não puderam ser verificadas, mas continham declarações consideradas imprecisas, enviesadas, alarmistas ou perigosas, foram anotadas como desinformação. Se nenhum dos critérios são encontrados, a mensagem é anotada como não-desinformação.

4. Metodologia

Este trabalho experimenta o uso de grandes modelos de linguagem (LLMs) com *embeddings* contextuais na tarefa de detecção de desinformação no conjunto de dados COVID.BR, comparando com os resultados obtidos com modelos de classificação preditivos com *embeddings* fixas em [Martins et al. 2021b]. A Figura 1 resume visualmente a organização e as etapas metodológicas aplicadas na pesquisa.

A Análise Exploratória de Dados é a etapa inicial da metodologia, e é realizada sob o conjunto de dados com objetivo de analisar sua estrutura, padrões e anomalias, e compreender como os atributos disponíveis em linguagem natural se relacionam com os rótulos de desinformação. Elaboram-se perguntas norteadoras, com objetivo de orientar o uso de ferramentas de exploração de dados e estatística descritiva para responder perguntas relevantes sobre os dados. Assim, a partir dos achados da exploração, é possível decidir sobre filtrar linhas, transformar atributos e propor diferentes experimentos com o conjunto de dados, buscando potencializar o desempenho dos modelos de linguagem que o consomem.

Os modelos de linguagem voltados para o Processamento de Linguagem Natural, os quais incluem as LLMs, podem ser organizados entre modelos de compreensão de linguagem natural (NLU) e geração de linguagem natural (NLG). [Lin 2024] define compreensão de linguagem natural (NLU) como uma tarefa computacional de extração de intenção e significado a partir de informações baseadas em texto. [Ferreira and Paraboni 2024] definem a geração de linguagem natural (NLG) como um campo que visa soluções computacionais que, a partir de dados linguísticos ou não linguísticos com diversas representações de significado, gerem automaticamente linguagem natural. Na tentativa de entender qual destas classes de modelos de linguagem pode indicar uma melhor performance na tarefa de detecção de desinformação, realizaram-se




Figura 1. Etapas da metodologia proposta

experimentos para cada uma destas duas abordagens.

Existem diversas abordagens para continuar o pré-treinamento de um modelo de linguagem, já treinado em dados em larga escala. Segundo [Jurafsky and Martin 2025], *fine-tuning* se refere a um conjunto de técnicas que envolvem a continuação do treinamento de um modelo pré-treinado, com etapas adicionais para novos dados. Esta foi escolhida como uma técnica de continuação do pré-treinamento adequada para ajustar os modelos ao *COVID.BR* em ambos os experimentos, visando maximizar o seu desempenho com poucos dados.

Para os experimentos com NLU, o BERT (*Bidirecional Encoder Representations from Transformers*) foi empregado como uma arquitetura para modelos de compreensão capaz de gerar representações vetoriais (*embeddings*) contextuais para classificação. Adotou-se particularmente o modelo pré-treinado para português brasileiro BERTimbau. O BERTimbau foi treinado no *Brazilian Web as Corpus* (brWaC), um conjunto de páginas web brasileiras que somam 2.68 bilhões de *tokens* extraídos de 3.52 milhões de documentos [Souza et al. 2023]. O modelo em sua versão base tem 110 milhões de parâmetros, e sua maior versão tem 335 milhões de parâmetros.

Para os experimentos com NLG, foram analisados diversos modelos *open-source*, com acesso integral e gratuito aos pesos de treinamento. Visando a possibilidade de realizar *fine-tuning* do modelo, foi utilizado como base o *Open Portuguese LLM Leaderboard* de [Garcia 2024], para selecionar potenciais modelos *open-source* com uma boa relação de compromisso entre desempenho e tamanho viável para ser treinado experimentalmente, considerando os recursos de hardware disponíveis para esta pesquisa. Considerando este critério, foram selecionados dois modelos generativos pré-treinados desenvol-

vidos pela empresa Alibaba: *Qwen/Qwen2.5-0.5B-Instruct* e *Qwen/Qwen3-0.6B*. Ambos possuem desempenho similar, porém o modelo *Qwen3* implementa múltiplas otimizações na arquitetura para melhorar eficiências nos parâmetros comparado ao modelo anterior *Qwen2.5*. Essa mudança consiste na substituição de *transformers* densos por um design mais inteligente de *Mixture-of-Experts* (MoE), resultando no aumento de desempenho e uma redução no uso de recursos computacionais [Yang et al. 2025]. Outro diferencial do modelo escolhido é a possibilidade de adicionar uma camada de saída para classificação, assim podemos utilizar a arquitetura com foco em NLG, porém obtendo uma saída concreta das classes esperadas.

Visto o objetivo geral de comparar os resultados destes experimentos com [Martins et al. 2021b], adotou-se a mesma metodologia de avaliação e métricas de desempenho propostas. Os autores utilizam *k-fold cross-validation* com $k = 5$ *folds* para avaliar diferentes combinações de algoritmos de classificação com métodos de extração de atributos. Com isto, realizam a estimativa de desempenho de seus experimentos com as métricas *F1-score* (F1), precisão (PRE), revocação (REC) e taxa de falso-positivos (FPR).

5. Análise exploratória dos dados

A análise exploratória visa identificar os tipos de atributos disponíveis, entender a distribuição das variáveis e balanceamento do atributo alvo no *dataset* COVID.BR, assim como detectar valores faltantes ou anômalos. A exploração foi organizada em torno das seguintes perguntas norteadoras, que serviram como guia para a compreensão dos dados:

- **P1.** Qual a quantidade e tipos de atributos?
- **P2.** Quais são os padrões e anomalias nos dados?
- **P3.** Qual a distribuição do atributo alvo?

5.1. Quantidade e tipos de atributos

O *dataset* rotulado apresenta 2.899 amostras relativas a mensagens individuais do *WhatsApp*, com atributos como: o texto da mensagem (*text*), do tipo object; o número de compartilhamentos (*shares*) e o rótulo de desinformação (*misinformation*), do tipo int64; a fonte utilizada para a verificação de fatos (*source*), do tipo object; e o número da revisão da verificação (*revision*), do tipo float64. O atributo alvo é o ‘*misinformation*’, um atributo numérico binário para classificação, onde o rótulo 0 significa que a instância foi rotulada como ‘não-desinformação’, e o rótulo 1 significa que a instância foi rotulada como ‘desinformação’.

5.2. Padrões e anomalias

O atributo texto de cada mensagem foi descrito em termos do número de mensagens únicas e estatísticas descritivas básicas relacionadas ao número de *tokens* das mensagens, como média, desvio padrão, mínimo e máximo. A Tabela 2 apresenta as estatísticas descritivas, divididas entre as classes de rotulação. A Figura 2 apresenta o *box-plot* que sumariza em escala logarítmica a descrição do número de *tokens* do atributo texto por classe do atributo alvo. Apesar de um grande número de amostras discrepantes rotuladas como não-desinformação, a média do número de *tokens* por mensagem para amostras




Figura 2. Número de tokens do atributo texto por classe do atributo alvo

Tabela 2. Estatísticas descritivas básicas sobre o *dataset* COVID.BR rotulado

Estatística	Não-desinformação (0)	Desinformação (1)
Contagem de mensagens únicas	1986	912
Média e desvio padrão do número de <i>tokens</i> das mensagens	78.96 ± 261.10	171.17 ± 290.26
Número de <i>tokens</i> mínimo	1	1
Número de <i>tokens</i> mediano	15	50
Número de <i>tokens</i> máximo	5.938	4.862
Tamanho médio de palavras (em caracteres)	6.44	5.16

rotuladas como desinformação é maior do que para as amostras rotuladas como não-desinformação, com um desvio padrão similar.

Quanto a atributos nulos, identificou-se apenas uma amostra com texto nulo, atribuído com o rótulo de desinformação. Esta instância foi filtrada do conjunto de dados, visto que uma mensagem vazia não pode ser considerada uma mensagem válida para consideração.

No atributo texto, as mensagens são compostas também por *emojis* e *URLs*. Martins et al. (2021) indica que instâncias com *URLs*, no contexto de tokenizadores como *Bag of Words* e *TF-IDF*, podem dificultar a classificação com modelos preditivos clássicos. Por isto, buscou-se analisar os padrões e possíveis anomalias de mensagens com estes tipos de palavras. A Tabela 3 apresenta as expressões regulares utilizadas para a busca de *URLs* nas mensagens, visto que podem haver ocorrências falso-negativas.

No conjunto de dados, existem 1572 instâncias de texto que contém ocorrências *URLs* em seu conteúdo, onde 605 instâncias são textos que apenas iniciam com ocorrências e 498 instâncias são textos compostos exclusivamente por *URLs*. Complementarmente, 1326 instâncias não contém ocorrências de *URLs* no texto. A Figura 3

Tabela 3. Expressões regulares utilizadas para a busca de ocorrências de *URLs* nas mensagens

Busca	Expressão regular
Mensagens que contêm qualquer ocorrência de <i>URLs</i>	<code>(https?:\/\/[^\s]+ www\.[^\s]+ \b [^\s]+?\.(com br org net gov edu pt) \b</code>
Mensagens que começam com <i>URLs</i>	<code>^(https?:\/\/[^\s]+ ^www\.[^\s]+ ^\b [^\s]+?\.(com br org net gov edu pt) \b</code>
Mensagens que contêm exclusivamente <i>URLs</i>	<code>^(https?:\/\/[^\s]+ ^www\.[^\s]+ ^\b [^\s]+?\.(com br org net gov edu pt)) \$</code>




Figura 3. Distribuição de classes por tipo de mensagem

mostra um gráfico da quantidade de amostras que contém, não contém ou são compostas apenas por *URLs*, segmentada pelas classes do atributo alvo. É possível verificar que das amostras que contém *URLs* no corpo da mensagem, existem 1304 rotuladas como não-desinformação e 268 como desinformação, uma diferença significativa. Amostras compostas exclusivamente *URLs* confirmam a tendência, com 491 amostras rotuladas como não-desinformação e apenas 7 como desinformação. Já em mensagens sem ocorrência de qualquer *URL*, o número de amostras para cada classe é aproximado, com 682 amostras rotuladas como não-desinformação e 644 como desinformação. Portanto, este padrão pode ser uma característica importante na separação dos dados na tarefa de classificação, tendo em vista um método de tokenização que seja capaz de extrair características relevantes destes links para o modelo empregado.

Em [Martins et al. 2021b], os *emojis* são separados por espaços em branco no pré-processamento, para garantir sua tokenização individual, mas não há uma análise de seus padrões de ocorrência em relação ao atributo alvo. Por isto, foi realizada uma contagem do número de *emojis* contidos no atributo texto, com objetivo de compreender como sua ocorrência pode se relacionar com a classificação. Calculou-se a taxa de ocorrência de *emojis* por mensagem, visando compreender como a predominância de *emojis* no comprimento da mensagem pode indicar tendências para a separação de dados no atributo alvo. O conjunto de dados apresenta uma média de 1.95 ± 9.41 *emojis* por mensagem,




Figura 4. Distribuição do uso de emojis nas mensagens




Figura 5. Distribuição do atributo alvo

assim como uma taxa média de 0.0045 ± 0.018 *emojis* por tamanho da mensagem. A Figura 4 apresenta um *box-plot* do número de *emojis* por mensagem e a taxa de *emojis* por mensagem, em escala logarítmica e estratificada pela classe desinformação. Verifica-se a predominância de amostras discrepantes, indicando uma variação muito esparsa com baixa concentração na média. Portanto, não é possível verificar uma relação clara entre a ocorrência de *emojis* nas mensagens e o rótulo de desinformação.

5.3. Distribuição do atributo alvo

O atributo de desinformação neste conjunto de dados apresenta um alto desbalanceamento, pois a classe de não-desinformação tem 1987 instâncias (68,54%) e a classe de desinformação apenas 912 (31,46%). A Figura 5 apresenta a distribuição para o atributo.

6. Resultados

A descrição dos experimentos, parametrizações e resultados foram organizadas em subseções. A seção 6.1 aborda as etapas de pré-processamento no conjunto de dados. Os experimentos para modelos de compreensão (NLU) são abordados na seção 6.2, e os experimentos para modelos de geração (NLG) são abordados na seção 6.3. Por fim, a seção 6.4 compara os resultados quantitativos dos experimentos utilizando as métricas de avaliação definidas.

6.1. Pré-processamento

As etapas de pré-processamento envolveram a limpeza dos dados, a criação de variações do conjunto, e a aplicação de tokenizadores diferentes, de acordo com cada experimento. Na etapa de limpeza, foi filtrada apenas uma instância do conjunto original rotulado por ocorrência de valores nulos. Dadas as diferenças na distribuição de classe relativas à ocorrência de *URLs*, criou-se três versões do conjunto de dados para serem experimentadas: completa (*Complete Dataset*); filtradas instâncias que contém *URLs* no início do texto (*No Start URL*); e filtradas instâncias que contém qualquer ocorrência de *URLs* no texto (*No URL*).

6.2. NLU: Fine-tuning do BERTimbau

O experimento com NLU utiliza o ‘*bert-base-portuguese-cased*’ (BERTimbau Base) como modelo pré-treinado de compreensão de linguagem. Por ser aberto, foi possível realizar o fine-tuning deste modelo para os três conjuntos de dados experimentais. Estes dados foram tokenizados com o *BertTokenizer*. Utilizou-se a arquitetura BERT para classificação de sequências (*BertForSequenceClassification*), composto por um *transformer* BERT com uma camada linear de classificação na saída agrupada (*pooled output*). A Tabela 4 apresenta os hiperparâmetros utilizados no treinamento.

Tabela 4. Hiperparâmetros utilizados no fine-tuning do BERTimbau

Hiperparâmetros	Valores
Nome do modelo	neuralmind/bert-base-portuguese-cased
Tamanho do vocabulário	29794
Tamanho máximo da sequência	512
Tamanho do <i>batch size</i>	8
Número de épocas	15
Taxa de aprendizado	1e-06
Semente aleatória	42
Otimizador	Adamw
Estratégia de avaliação	Por época
Precisão mista (FP16/BF16)	Não
Temperatura	1.0
Top K	50
Top P	1.0

Visto o desbalanceamento de classes, observado na Figura 3, foi realizada uma estimativa de pesos para cada classe, para cada conjunto de dados, e aplicada no cálculo do *Cross Entropy Loss* durante o treinamento. A Equação 1 apresenta o cálculo da estimativa,




Figura 6. Métricas do modelo BERT

onde $n_{samples}$ é o número de amostras do conjunto de dados, $n_{classes}$ é o número de classes do atributo alvo e (x_{count}, y_{count}) é uma tupla com o número de instâncias de cada classe para um atributo binário.

$$n_{samples} / (n_{classes} * (x_{count}, y_{count})) \quad (1)$$

O *fine-tuning* foi realizado para os três conjuntos de dados e avaliado com validação cruzada, para $k = 5$ folds. A Figura 6 apresenta os *box-plots* do modelo ajustado por variação do conjunto de dados, para as métricas propostas comparadas com os valores médios reportados para o melhor experimento em [Martins et al. 2021b].

6.3. NLG: Fine-tuning do Qwen3-0.6B

Para a tarefa de geração de linguagem natural (NLG), foi utilizado o modelo pré-treinado *Qwen3-0.6B*, um modelo de linguagem da série *Qwen3* desenvolvido pela *Alibaba Cloud*. O processo de *fine-tuning* foi conduzido para adaptar o modelo à tarefa de classificação de sequências para identificar desinformação no conjunto de dados.

O *fine-tuning* foi realizado utilizando a biblioteca *transformers* e também seguiu uma metodologia de validação cruzada estratificada com $k = 5$ folds. A arquitetura empregada foi a *AutoModelForSequenceClassification*, que anexa uma camada linear de classificação ao topo do modelo base para a tarefa com duas classes ($num_labels=2$).

Tabela 5. Hiperparâmetros utilizados no fine-tuning do Qwen3-0.6B.

Hiperparâmetros	Valores
Nome do modelo	Qwen/Qwen3-0.6B
Tamanho máximo da sequência	1024
Tamanho do <i>batch size</i>	1
Número de épocas	5
Taxa de Aprendizado	4×10^{-5}
Acumulação de Gradiente	4
Semente aleatória	42
Otimizador	AdamW
Estratégia de avaliação	Por época
Precisão mista (FP16/BF16)	Sim

Os dados foram tokenizados utilizando o *AutoTokenizer* correspondente ao modelo Qwen3, com um comprimento máximo de sequência de 1024 tokens.

Para gerenciar as restrições de memória da *GPU*, o treinamento utilizou um *batch size* de 1, combinado com 4 passos de acumulação de gradiente, o que, na prática, simula um *batch* efetivo de tamanho 4. Adicionalmente, para reduzir ainda mais o uso de memória, foi habilitada a precisão mista. A combinação dessas estratégias permitiu realizar o *fine-tuning* diretamente no modelo base, sem a necessidade de aplicar técnicas de quantização. A Tabela 5 detalha os hiperparâmetros utilizados no experimento.

Durante a validação cruzada, o modelo com o melhor desempenho em cada *fold*, avaliado pela métrica *F1-score*, era salvo. Ao final dos 5 *folds*, os resultados das métricas de avaliação foram agregados, calculando-se a média e o desvio padrão para fornecer uma avaliação do desempenho do modelo. A Figura 7 apresenta os resultados consolidados deste experimento.

6.4. Comparação entre os experimentos

Dos experimentos com abordagens em NLG e NLU, foram selecionados os dois modelos que obtiveram um melhor valor médio na métrica principal, o *F1-score*. Em ambos os experimentos, o conjunto de dados completo do *COVID.BR* apresentou o melhor desempenho após *fine-tuning* para ambas abordagens. A Figura 8 apresenta o *box-plot* que compara os melhores modelos obtidos em termos de *F1-score* nos dois experimentos. Os dois modelos obtiveram um desempenho similar em termos da métrica principal.

O modelo ajustado com o *BERTimbau* obteve um valor médio de *F1-score* de 0.857 ± 0.018 , enquanto o ajustado com o *Qwen3-0.6B* obteve uma média de 0.787 ± 0.030 . Em [Martins et al. 2021b] melhor experimento com SVM reporta um *F1-score* médio de 0.778, próximo do resultado obtido com *Qwen3*, enquanto o *BERTimbau* apresenta um ganho significativo de desempenho. Em termos da Taxa de Falso-Positivos (FPR), o modelo ajustado sobre o *Qwen3-0.6B* demonstrou um melhor desempenho, com média de 0.102 ± 0.040 , e o *BERTimbau* obteve uma média de 0.142 ± 0.020 . Este último apresentou uma FPR similar ao reportado por [Martins et al. 2021b], com um valor médio de 0.146. Ou seja, o modelo baseado na série *Qwen3* obteve uma pequena melhoria em relação ao número de amostras falso-positivas durante a estimativa de desempenho, o que é relevante para que não se classifique imprecisamente como desinformação mensagens que não se




Figura 7. Métricas do modelo Qwen

encaixam na definição desta classe.

7. Conclusão

Dentre os experimentos executados, o BERTimbau como arquitetura de compreensão de linguagem natural (NLU) demonstrou um ganho de desempenho em relação às abordagens com algoritmos preditivos clássicos. Isto pode indicar que os *embeddings* contextuais em uma arquitetura *transformer encoder-only* são mais adequados para classificação de desinformação em mensagens de texto, ao contrário dos *embeddings* fixos utilizados para as abordagens preditivas. É possível indicar também que, para esta tarefa, os modelos com arquitetura *encoder-only* devem apresentar um melhor desempenho em relação aos modelos com arquiteturas *decoder-only*, os quais representam os modelos de geração de linguagem natural (NLG).

Com isto, modelos de linguagem com *embeddings* contextuais se mostram como uma ferramenta potencial para a detecção de desinformação, com dados rotulados, em grandes plataformas de comunicação como o *WhatsApp*. O emprego destes modelos em uma grande plataforma pode ter reflexos na redução da propagação de mensagens com desinformação sobre COVID-19, impactando a adoção de medidas sanitárias e beneficiando a saúde coletiva da população mundial. Com processos bem definidos de verificação de fatos, é possível automatizar e escalar a criação de rótulos para manter o treinamento de modelos que detectam diversos tipos de desinformação, *fake-news* e discursos de ódio, auxiliando usuários a garantirem sua segurança e direito à informação nos meios digitais.




Figura 8. Comparação entre modelos

que permeiam a sociedade como um todo.

Referências

- Alghamdi, J., Lin, Y., and Luo, S. (2023). Towards covid-19 fake news detection using transformer-based models. *Knowledge-Based Systems*, 274.
- Ferreira, T. C. and Paraboni, I. (2024). *Geração de linguagem natural*, pages 341–364. BPLN, 3rd edition.
- Galhardi, C. P., Freire, N. P., de Souza Minayo, M. C., and Fagundes, M. C. M. (2020). Fato ou fake? uma análise da desinformação frente à pandemia da covid-19 no brasil. *Ciência & Saúde Coletiva*, 25:4201–4210.
- Garcia, E. A. S. (2024). Open portuguese llm leaderboard. https://huggingface.co/spaces/eduagarcia/open_pt_llm_leaderboard.
- Jurafsky, D. and Martin, J. H. (2025). Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition with language models. Online manuscript released January 12, 2025.
- Lin, B. (2024). Reinforcement learning and bandits for speech and language processing: Tutorial, review and outlook. *Expert Systems with Applications*, 238:122254.
- Martins, A. D. F., Cabral, L., Mourão, P. J. C., de Sá, I. C., Monteiro, J. M., and Machado, J. (2021a). Covid19.br: A dataset of misinformation about covid-19 in brazilian portu-

- guese whatsapp messages. In *Anais do III Dataset Showcase Workshop (DSW 2021)*, pages 138–147. Sociedade Brasileira de Computação.
- Martins, A. D. F., Cabral, L., Mourão, P. J. C., Monteiro, J. M., and Machado, J. (2021b). *Detection of Misinformation About COVID-19 in Brazilian Portuguese WhatsApp Messages*, pages 199–206. Springer International Publishing, 1st edition.
- Massuchin, M. G., Tavares, C. Q., Mitozo, I. B., and de Souza Chagas, V. H. C. (2021). A estrutura argumentativa do descrédito na ciência. *Fronteiras - estudos midiáticos*, 23:160–174.
- Organização Mundial da Saúde (2020). Who director-general’s opening remarks at the media briefing on covid-19 - 11 march 2020. <https://www.who.int/director-general/speeches/detail/who-director-general-s-opening-remarks-at-the-media-briefing-on-covid-19---11-march-2020>. Acesso em: 28 jun. 2025.
- Organização Mundial da Saúde (2021). Who public health research agenda for managing infodemics. <https://www.who.int/publications/i/item/9789240019508>. Acesso em: 28 jun. 2025.
- Soares, F. B., Recuero, R., Volcan, T., Fagundes, G., and Sodr , G. (2021). Desinforma  o sobre o covid-19 no whatsapp: a pandemia enquadrada como debate pol tico. *Ci ncia da Informa  o em Revista*, 8:74–94.
- Souza, F. C., Nogueira, R. F., and Lotufo, R. A. (2023). Bert models for brazilian portuguese: Pretraining, evaluation and tokenization analysis. *Applied Soft Computing*, 149:110901.
- Su, Q., Wan, M., Liu, X., and Huang, C.-R. (2020). Motivations, methods and metrics of misinformation detection: An nlp perspective. *Natural Language Processing Research*, 1:1.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Łukasz Kaiser, and Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 2017-December:5999–6009.
- Vijaykumar, S., Jin, Y., Rogerson, D., Lu, X., Sharma, S., Maughan, A., Fadel, B., de Oliveira Costa, M. S., Pagliari, C., and Morris, D. (2021). How shades of truth and age affect responses to covid-19 (mis)information: randomized survey experiment among whatsapp users in uk and brazil. *Humanities and Social Sciences Communications* 2021 8:1, 8:1–12.
- Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Gao, C., Huang, C., Lv, C., Zheng, C., Liu, D., Zhou, F., Huang, F., Hu, F., Ge, H., Wei, H., Lin, H., Tang, J., Yang, J., Tu, J., Zhang, J., Yang, J., Yang, J., Zhou, J., Zhou, J., Lin, J., Dang, K., Bao, K., Yang, K., Yu, L., Deng, L., Li, M., Xue, M., Li, M., Zhang, P., Wang, P., Zhu, Q., Men, R., Gao, R., Liu, S., Luo, S., Li, T., Tang, T., Yin, W., Ren, X., Wang, X., Zhang, X., Ren, X., Fan, Y., Su, Y., Zhang, Y., Zhang, Y., Wan, Y., Liu, Y., Wang, Z., Cui, Z., Zhang, Z., Zhou, Z., and Qiu, Z. (2025). Qwen3 technical report.